

Bondad del ajuste en el modelo de regresión lineal

Contents

1	Coefficiente de determinacion R^2	1
2	Coefficiente de determinacion ajustado R_a^2	2
3	Ejemplo	3

Se quiere evaluar como de bueno es el modelo que se ha estimado. La calidad del modelo se puede calcular utilizando diferentes métricas:

1 Coeficiente de determinacion R^2

Dado unos datos $(x_{1i}, \dots, x_{ki}, y_i)$, $i = 1, \dots, n$, se estima el modelo de regresión lineal

$$y_i = \beta_0 + \beta_1 x_{1i} + \dots + \beta_k x_{ki} + u_i$$

obteniendo

$$y_i = \hat{\beta}_0 + \hat{\beta}_1 x_{1i} + \dots + \hat{\beta}_k x_{ki} + e_i$$

Es usual definir

$$\hat{y}_i = \hat{\beta}_0 + \hat{\beta}_1 x_{1i} + \dots + \hat{\beta}_k x_{ki}$$

por lo que

$$y_i = \hat{y}_i + e_i$$

Ya hemos visto que a partir de esta expresión se obtiene:

$$\sum_{i=1}^n (y_i - \bar{y})^2 = \sum_{i=1}^n (\hat{y}_i - \bar{y})^2 + \sum_{i=1}^n e_i^2$$

$$SCT = SCM + SCR$$

donde:

- SCT: suma de cuadrados total
- SCM: suma de cuadrados correspondientes al modelo.
- SCR: suma de cuadrados correspondientes a los residuos.

Es decir, dividimos la suma de cuadrados total entre modelo y residuos. Por tanto es lógico definir un coeficiente dividiendo SSM entre SST , es decir, calcular el porcentaje de la suma de cuadrados que corresponde al modelo. Dicho coeficiente se llama **coeficiente de determinación**:

$$R^2 = \frac{SSM}{SST} = 1 - \frac{SSE}{SST}$$

Este coeficiente toma valores entre 0 y 1:

- Si el modelo es bueno, la suma de cuadrados del modelo será grande, $R^2 \approx 1$.
- Si el modelo es malo, la suma de cuadrados del modelo será pequeña, $R^2 \approx 0$.

2 Coeficiente de determinación ajustado R_a^2

Sea el modelo

$$y = \beta_0 + \beta_1 x_1 + \cdots + \beta_k x_k + u$$

El coeficiente de determinación para este modelo es

$$R^2 = 1 - \frac{SSE}{SST} = 1 - \frac{(n - k - 1)\hat{s}_R^2}{(n - 1)\hat{s}_y^2}$$

Supongamos que se añade un regresor más x_{k+1} que no aporta información al modelo, es decir, $\beta_{k+1} = 0$. En principio el modelo sería:

$$y = \beta_0 + \beta_1 x_1 + \cdots + \beta_k x_k + \beta_{k+1} x_{k+1} + u$$

y su coeficiente de determinación, R_1^2 , sería:

$$R_1^2 = 1 - \frac{(n - (k + 1) - 1)\hat{s}_R^2}{(n - 1)\hat{s}_y^2} = 1 - \frac{(n - (k + 1) - 1)\hat{s}_R^2}{(n - 1)\hat{s}_y^2}$$

En principio se debería cumplir que $R^2 = R_1^2$, ya que es ambos modelos son iguales. Sin embargo,

$$\begin{aligned} (n - (k + 1) - 1) &< (n - k - 1) \\ (n - (k + 1) - 1)\hat{s}_R^2 &< (n - k - 1)\hat{s}_R^2 \\ \frac{(n - (k + 1) - 1)\hat{s}_R^2}{(n - 1)\hat{s}_y^2} &< \frac{(n - k - 1)\hat{s}_R^2}{(n - 1)\hat{s}_y^2} \\ -\frac{(n - (k + 1) - 1)\hat{s}_R^2}{(n - 1)\hat{s}_y^2} &> -\frac{(n - k - 1)\hat{s}_R^2}{(n - 1)\hat{s}_y^2} \\ 1 - \frac{(n - (k + 1) - 1)\hat{s}_R^2}{(n - 1)\hat{s}_y^2} &> 1 - \frac{(n - k - 1)\hat{s}_R^2}{(n - 1)\hat{s}_y^2} \\ R_1^2 &> R^2 \end{aligned}$$

Por tanto, el coeficiente de determinación aumenta al aumentar el número de regresores k , aunque esos regresores no aporten información al modelo. Por este motivo se define el coeficiente de determinación ajustado o corregido:

$$R_a^2 = 1 - \frac{\hat{s}_R^2}{\hat{s}_y^2} = 1 - \frac{SCR/(n-k-1)}{SCT/(n-1)} = 1 - \frac{SCR}{SCT} \frac{(n-1)}{(n-k-1)}$$

Este coeficiente intenta corregir este fenómeno. Cuando comparamos modelos con diferente número de regresores es preferible utilizar R_a^2 .

3 Ejemplo

```
load("datos/kidiq.Rdata")
str(d)

## 'data.frame':  434 obs. of  5 variables:
## $ kid_score: int  65 98 85 83 115 98 69 106 102 95 ...
## $ mom_hs   : Factor w/ 2 levels "no","si": 2 2 2 2 2 1 2 2 2 2 ...
## $ mom_iq   : num  121.1 89.4 115.4 99.4 92.7 ...
## $ mom_work : Factor w/ 4 levels "notrabaja","trabaja23",...: 4 4 4 3 4 1 4 3 1 1 ...
## $ mom_age  : int  27 25 27 25 27 18 20 23 24 19 ...

m1 = lm(kid_score ~ mom_iq + mom_age + mom_hs + mom_work, data = d)
summary(m1)

##
## Call:
## lm(formula = kid_score ~ mom_iq + mom_age + mom_hs + mom_work,
##     data = d)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -54.414 -12.095   2.015  11.653  49.100
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)    20.27273     9.39320   2.158  0.0315 *
## mom_iq          0.55288     0.06138   9.008 <2e-16 ***
## mom_age         0.21629     0.33351   0.649  0.5170
## mom_hssi        5.43466     2.32518   2.337  0.0199 *
## mom_worktrabaja23 2.98266     2.81289   1.060  0.2896
## mom_worktrabajalp 5.48824     3.25239   1.687  0.0922 .
## mom_worktrabajalc 1.41929     2.51621   0.564  0.5730
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 18.14 on 427 degrees of freedom
## Multiple R-squared:  0.2213, Adjusted R-squared:  0.2103
## F-statistic: 20.22 on 6 and 427 DF,  p-value: < 2.2e-16

m2 = lm(kid_score ~ mom_iq + mom_age + mom_hs, data = d)
summary(m2)

##
```

```
## Call:
## lm(formula = kid_score ~ mom_iq + mom_age + mom_hs, data = d)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -53.289 -12.421   2.399  11.223  50.169
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)  20.98466    9.13013   2.298  0.0220 *
## mom_iq        0.56254    0.06065   9.276 <2e-16 ***
## mom_age       0.22475    0.33075   0.680  0.4972
## mom_hssi      5.64715    2.25766   2.501  0.0127 *
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 18.15 on 430 degrees of freedom
## Multiple R-squared:  0.215, Adjusted R-squared:  0.2095
## F-statistic: 39.25 on 3 and 430 DF, p-value: < 2.2e-16
```

Se tiene que $R_{a1}^2 = 0.2103$, $R_{a2}^2 = 0.2095$. Según acabamos de comprobar, el R-cuadrado de m1 es mayor ya que utiliza más regresores. La cuestión es si esta diferencia se debe a que m1 es mejor que m2 o ambos son comparables. Para comprobarlo utilizamos el contraste

- H_0 : Los modelos m1 y m2 son equivalentes.
- H_1 : Los modelos m1 y m2 NO son equivalentes.

```
anova(m1,m2)
```

```
## Analysis of Variance Table
##
## Model 1: kid_score ~ mom_iq + mom_age + mom_hs + mom_work
## Model 2: kid_score ~ mom_iq + mom_age + mom_hs
##   Res.Df    RSS Df Sum of Sq    F Pr(>F)
## 1      427 140471
## 2      430 141605 -3    -1134.2 1.1493 0.3289
```

El p-valor > 0.05 , no se rechaza la hipótesis nula, los modelos son equivalentes. Seguramente se debe a que la variable *mom_work* no es significativa, no aporta información:

```
summary(m1)
```

```
##
## Call:
## lm(formula = kid_score ~ mom_iq + mom_age + mom_hs + mom_work,
##     data = d)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -54.414 -12.095   2.015  11.653  49.100
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)  20.27273    9.39320   2.158  0.0315 *
## mom_iq        0.55288    0.06138   9.008 <2e-16 ***
## mom_age       0.21629    0.33351   0.649  0.5170
## mom_hssi      5.43466    2.32518   2.337  0.0199 *
```

```
## mom_worktrabaja23 2.98266    2.81289    1.060    0.2896
## mom_worktrabaja1p 5.48824    3.25239    1.687    0.0922 .
## mom_worktrabaja1c 1.41929    2.51621    0.564    0.5730
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 18.14 on 427 degrees of freedom
## Multiple R-squared:  0.2213, Adjusted R-squared:  0.2103
## F-statistic: 20.22 on 6 and 427 DF,  p-value: < 2.2e-16
```