Árboles de regresión: K regresores

Contents

1 Arbol con regresores cuantitativos y cualitativos

```
library(rpart)
load("datos/kidiq.Rdata")
```

```
# method = "anova" para modelos de regresion
t1 = rpart(kid_score ~ ., data = d, method = "anova")
```

```
plot(t1, margin = 0.02)
text(t1, cex = 0.75, pretty = 0)
```

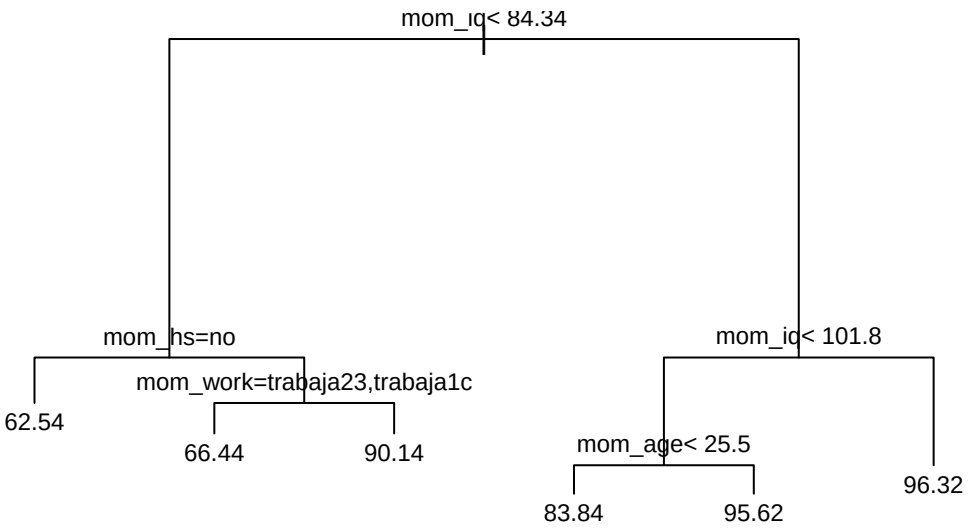


```
print(t1)
```

```
## n= 434
##
## node), split, n, deviance, yval
##       * denotes terminal node
##
```

```
##  1) root 434 180386.200 86.79724
##    2) mom_iq< 84.33641 69  29011.830 66.86957
##      4) mom_hs=no 35  11166.690 62.54286 *
##      5) mom_hs=si 34  16515.440 71.32353
##       10) mom_work=trabaja23,trabaja1c 27   9750.667 66.44444 *
##       11) mom_work=notrabaja,trabaja1p 7   3642.857 90.14286 *
##    3) mom_iq>=84.33641 365 118793.700 90.56438
##      6) mom_iq< 101.8061 191  58829.520 85.31937
##       12) mom_age< 25.5 167  51906.630 83.83832 *
##       13) mom_age>=25.5 24   4007.625 95.62500 *
##      7) mom_iq>=101.8061 174  48941.980 96.32184 *
```

Como vemos, cuando hay una variables cualitativa, se van asignando los diferentes niveles del factor a cada rama que sale del nodo hasta que se encuentra la asignación con menor SCR:

- En el nodo 2, si mom_hs = no, nos vamos hacia la izquierda; si mom_hs = si, nos vamos a la derecha.
- En el nodo 5, si mom_work = trabaja23,trabaja1_completo nos vamos a la izquierda; si mom_work=notrabaja,trabaja1_parcial nos vamos a la derecha.

2 Parámetros del árbol

```
t2 = rpart(kid_score ~ ., data = d, method = "anova",
    control = rpart.control(minsplit = 10, minbucket = 5, cp = 0.007))
plot(t2, margin = 0.02)
text(t2, cex=.75, pretty = 0)
```

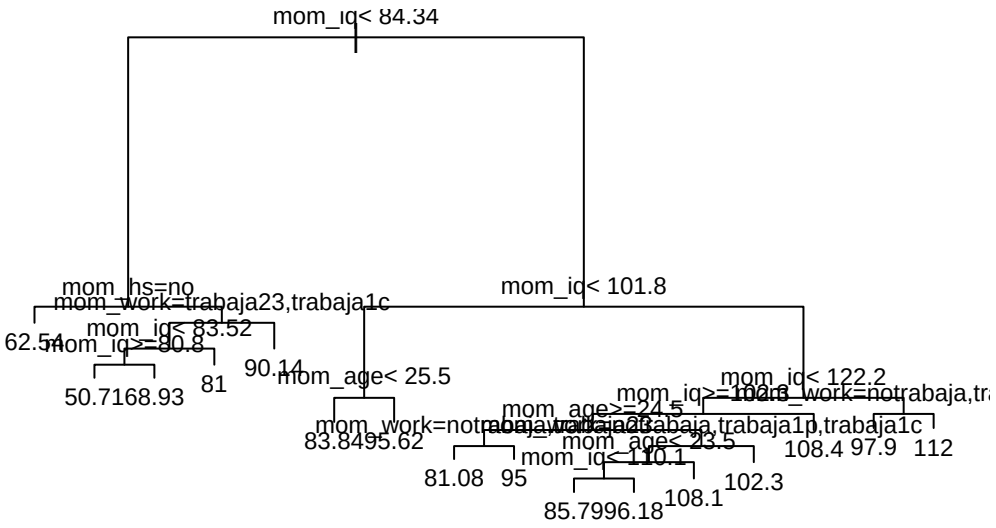


```
print(t2)
```

```
## n= 434
##
## node), split, n, deviance, yval
##       * denotes terminal node
##
##   1) root 434 180386.2000  86.79724
##     2) mom_iq< 84.33641 69  29011.8300  66.86957
##       4) mom_hs=no 35  11166.6900  62.54286 *
##       5) mom_hs=si 34  16515.4400  71.32353
```

```
##         10) mom_work=trabaja23,trabaja1c 27   9750.6670  66.44444
##           20) mom_iq< 83.51527 22   8034.5910  63.13636
##             40) mom_iq>=80.79538 7    545.4286  50.71429 *
##             41) mom_iq< 80.79538 15   5904.9330  68.93333 *
##           21) mom_iq>=83.51527 5    416.0000  81.00000 *
##         11) mom_work=notrabaja,trabaja1p 7   3642.8570  90.14286 *
##       3) mom_iq>=84.33641 365 118793.7000  90.56438
##         6) mom_iq< 101.8061 191  58829.5200  85.31937
##         12) mom_age< 25.5 167  51906.6300  83.83832 *
##         13) mom_age>=25.5 24   4007.6250  95.62500 *
##         7) mom_iq>=101.8061 174  48941.9800  96.32184
##         14) mom_iq< 122.2355 132  38970.8100  94.53788
##           28) mom_iq>=102.2658 127  36978.9900  93.99213
##             56) mom_age>=24.5 37  11611.2400  90.48649
##               112) mom_work=notrabaja,trabaja23 12   6398.9170  81.08333 *
##               113) mom_work=trabaja1p,trabaja1c 25   3642.0000  95.00000 *
##             57) mom_age< 24.5 90  24726.1000  95.43333
##               114) mom_work=notrabaja,trabaja1p,trabaja1c 69  19845.6500  93.34783
##                 228) mom_age< 23.5 61  17308.7500  91.40984
##                   456) mom_iq< 110.0551 28   7852.7140  85.78571 *
##                   457) mom_iq>=110.0551 33   7818.9090  96.18182 *
##                 229) mom_age>=23.5 8    560.8750 108.12500 *
##               115) mom_work=trabaja23 21   3594.2860 102.28570 *
##           29) mom_iq< 102.2658 5    993.2000 108.40000 *
##         15) mom_iq>=122.2355 42   8230.7860 101.92860
##           30) mom_work=notrabaja,trabaja1c 30   5234.7000  97.90000 *
##           31) mom_work=trabaja23,trabaja1p 12   1292.0000 112.00000 *
```

- Como vemos, en este caso el criterio que detiene el crecimiento del árbol es cp. Por ejemplo, el nodo 3 se ha dividido ya que

```
(118793.70 - 58829.52 - 48941.98)/180386.20
```

```
## [1] 0.06110334
```

- que es mayor que el límite cp $= 0.05$.
- Podemos construir un arbol más *profundo*:

```
t3 = rpart(kid_score ~ mom_iq, data = d, method = "anova",
    control = rpart.control(minsplit = 10, minbucket = 5, cp = 0.0069))
plot(t3, margin = 0.02)
text(t3, cex=.75)
```

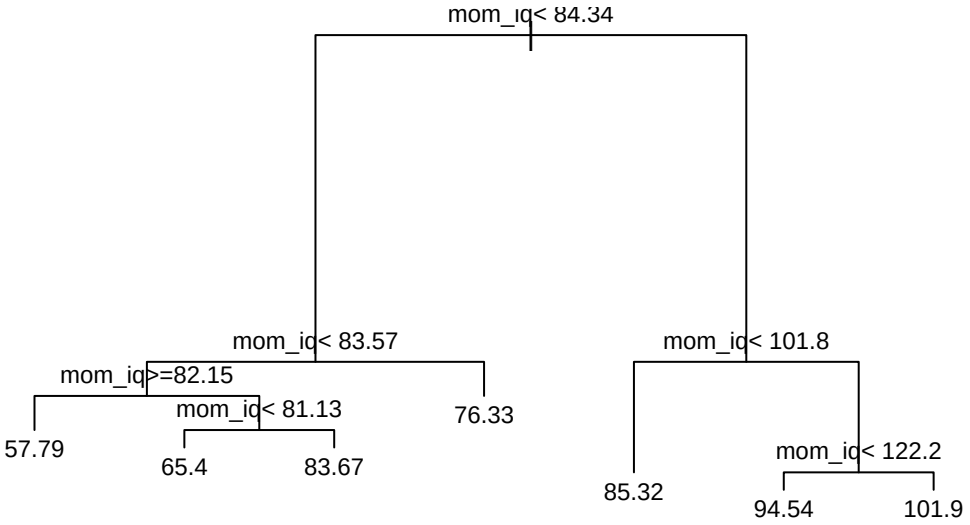


```
print(t3)
```

```
## n= 434
##
## node), split, n, deviance, yval
##       * denotes terminal node
##
##  1) root 434 180386.200  86.79724
##    2) mom_iq< 84.33641 69  29011.830  66.86957
##      4) mom_iq< 83.57478 60  26044.850  65.45000
##        8) mom_iq>=82.1513 14   5136.357  57.78571 *
##        9) mom_iq< 82.1513 46  19835.830  67.78261
##         18) mom_iq< 81.13004 40  14465.600  65.40000 *
##         19) mom_iq>=81.13004 6   3629.333  83.66667 *
##      5) mom_iq>=83.57478 9   2040.000  76.33333 *
##    3) mom_iq>=84.33641 365 118793.700  90.56438
##      6) mom_iq< 101.8061 191  58829.520  85.31937 *
##      7) mom_iq>=101.8061 174  48941.980  96.32184
##       14) mom_iq< 122.2355 132  38970.810  94.53788 *
##       15) mom_iq>=122.2355 42   8230.786 101.92860 *
```

- vemos que el nodo 7 en t2 no se dividía pero en t3 si se divide ya que:

```
(48941.980 - 38970.810 - 8230.786)/180386.200
```

```
## [1] 0.009648099
```

- De nuevo cp es el parámetro más restrictivo.

3 Residuos

```
plot(residuals(t3))
```

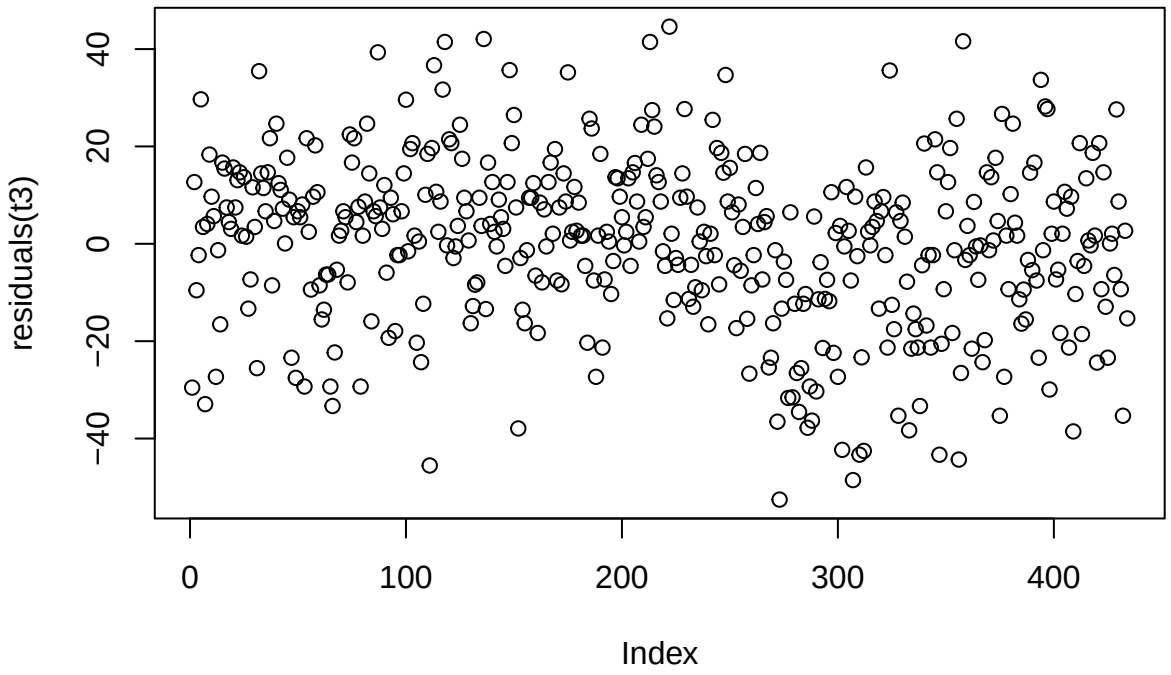

- El R2 se define a manera análoga a regresión

$$R^2 = 1 - \frac{SCR}{SCT}$$

- donde hay que recordar de SCR = deviance(nodo) y SCT = deviance(root)
- Se denomina error relativo al cociente SCR/SCT. Y la X indica que se ha calculado mediante validación cruzada.

```
par(mfrow = c(1,2))
rsq.rpart(t3)
```

```
##
## Regression tree:
## rpart(formula = kid_score ~ mom_iq, data = d, method = "anova",
##     control = rpart.control(minsplit = 10, minbucket = 5, cp = 0.0069))
##
## Variables actually used in tree construction:
## [1] mom_iq
##
## Root node error: 180386/434 = 415.64
##
## n= 434
##
##          CP nsplit rel error  xerror     xstd
## 1 0.1806158      0   1.00000 1.00860 0.065375
## 2 0.0611036      1   0.81938 0.84254 0.057826
## 3 0.0096481      2   0.75828 0.79752 0.055842
## 4 0.0069121      3   0.74863 0.83790 0.056484
## 5 0.0069000      6   0.72790 0.86347 0.059569
```

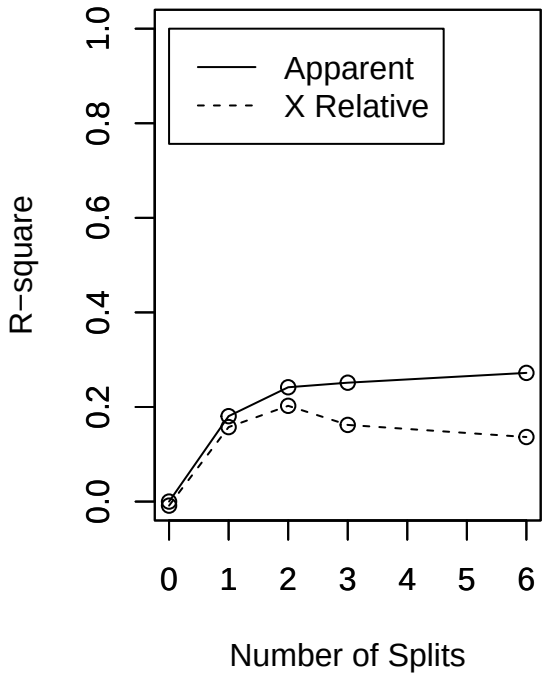

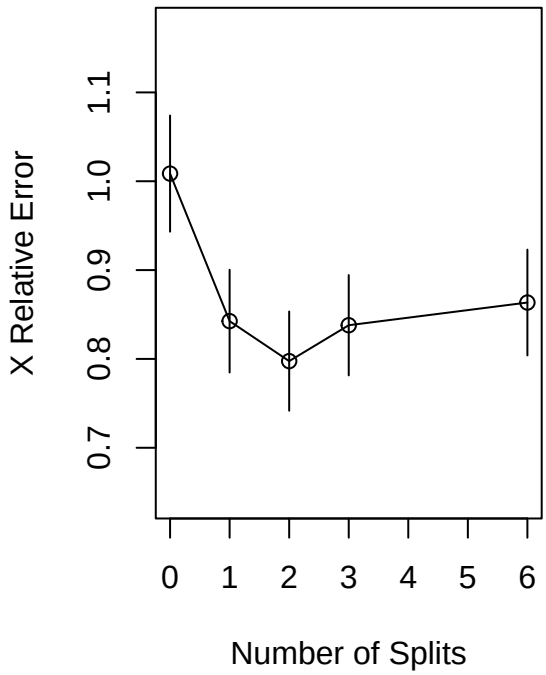

- Appatent: R2 calculado con la formula (1 - SCR/SCT)
- X Relative: R2 calculado con validación cruzada (como vemos, el R2 cuadrado con validación cruzada es menor que el apparent ya que uno esta calculado en los datos train y otro en los datos test).
- X relative error: 1 - X Relative, es decir, SCR/SCT. Está calculado con validación cruzada. Se dibuja el intervalo +/- SE calculado con validación cruzada.

4 Podado

- Los árboles que hemos visto se construyen de arriba hacia abajo, desde el nodo raiz hasta las hojas. Otra estrategia es construir un arbol muy profundo y luego podarlo. Construiriamos el arbol, por tanto, de abajo hacia arriba.
- Primero construimos un arbol profundo:

```
t4 = rpart(kid_score ~ ., data = d, method = "anova",
    control = rpart.control(minsplit = 2, cp = 0.005))
plot(t4, margin = 0.02)
text(t4, cex=.75)
```

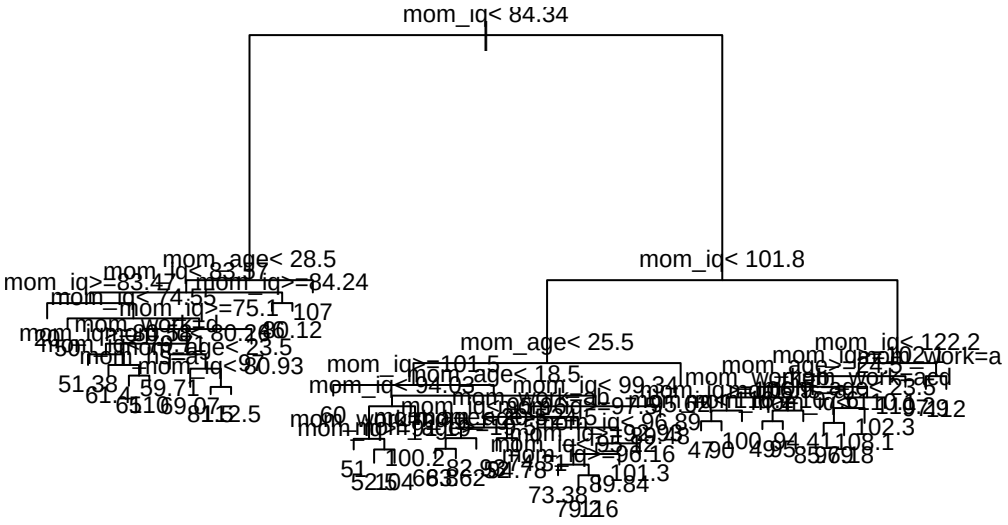

- Utilizando validación cruzada (el numero de validaciones viene dado por el parámetro xval), se determina el arbol con un determinado numero de hojas que tenga el mayor R2, o de manera equivalente, el menor error relativo.

```
t4_printcp = printcp(t4) # lo guardamos en una variable para utilizarlo despues
```

```
##
## Regression tree:
## rpart(formula = kid_score ~ ., data = d, method = "anova", control = rpart.control(minsplit = 2,
##     cp = 0.005))
##
## Variables actually used in tree construction:
## [1] mom_age  mom_hs   mom_iq   mom_work
##
## Root node error: 180386/434 = 415.64
##
## n= 434
##
##           CP nsplit rel error  xerror     xstd
## 1  0.1806158      0   1.00000 1.00411 0.065246
## 2  0.0611036      1   0.81938 0.84654 0.059189
## 3  0.0161612      2   0.75828 0.79563 0.056996
## 4  0.0123630      3   0.74212 0.81045 0.058082
## 5  0.0096481      6   0.70503 0.83692 0.061910
## 6  0.0094469      7   0.69538 0.88951 0.063623
## 7  0.0090591      8   0.68594 0.89221 0.063299
## 8  0.0085517      9   0.67688 0.92999 0.064675
## 9  0.0075110     11   0.65977 0.98372 0.071122
## 10 0.0073281     16   0.61596 1.01393 0.072558
## 11 0.0065568     22   0.57025 1.06045 0.074856
## 12 0.0065249     24   0.55713 1.11845 0.080086
## 13 0.0061137     26   0.54408 1.13364 0.081021
## 14 0.0060254     31   0.51109 1.13552 0.081042
## 15 0.0058459     35   0.48699 1.13273 0.081114
## 16 0.0057384     38   0.46945 1.13326 0.081119
## 17 0.0057263     39   0.46371 1.13377 0.081367
## 18 0.0055520     41   0.45226 1.13364 0.081456
## 19 0.0053275     43   0.44116 1.11119 0.079252
```

```
## 20 0.0050000     44   0.43583 1.14476 0.081229
```

- También se puede utilizar plotcp():

```
plotcp(t4)
```

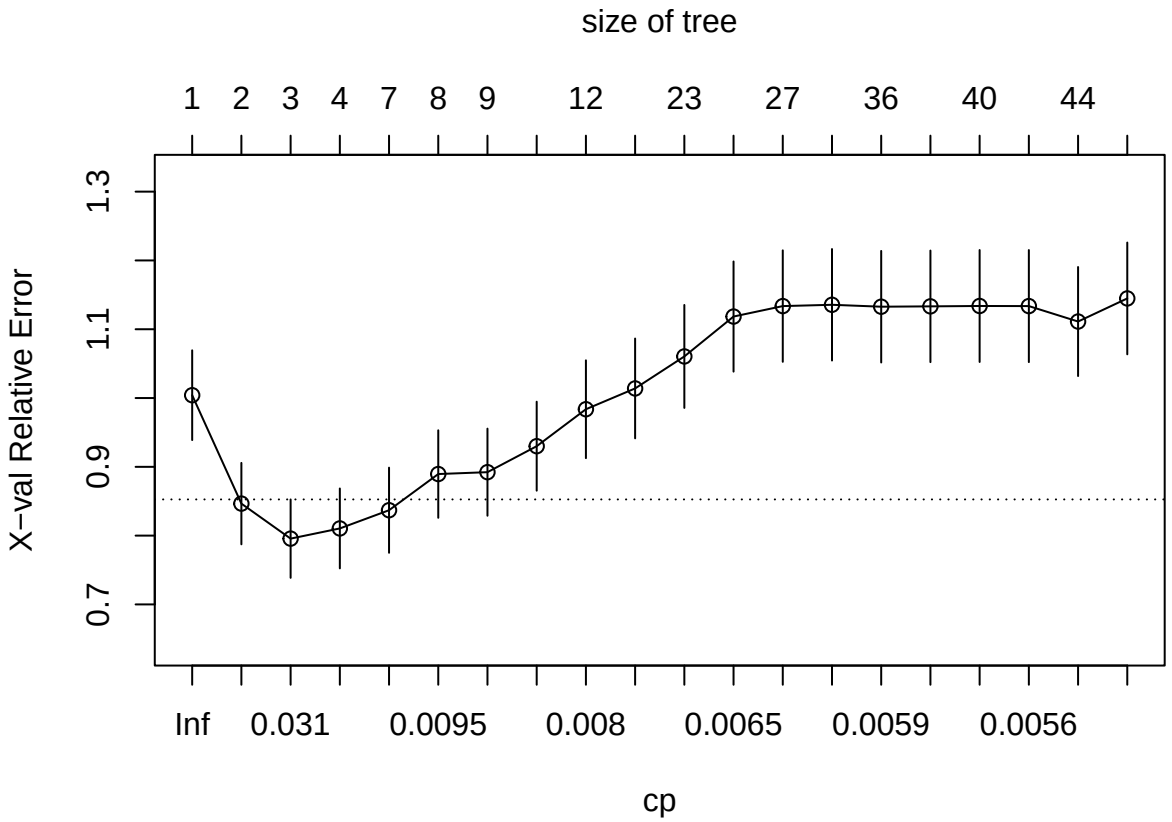

- A veces este gráfico tiene un mínimo, por lo que deberíamos seleccionar ese arbol. En caso contrario, elegimos el tamaño donde el error se estabilice.
- Según el gráfico y la tabla anterior, un arbol de 3 hojas parece razonable.

```
(t4_cp = t4_printcp[3,"CP"])
```

```
## [1] 0.01616121
```

- Ahora podamos el arbol:

```
t4_prune = prune(t4, cp = t4_cp)
plot(t4_prune, margin = 0.02)
text(t4_prune, cex=.75)
```

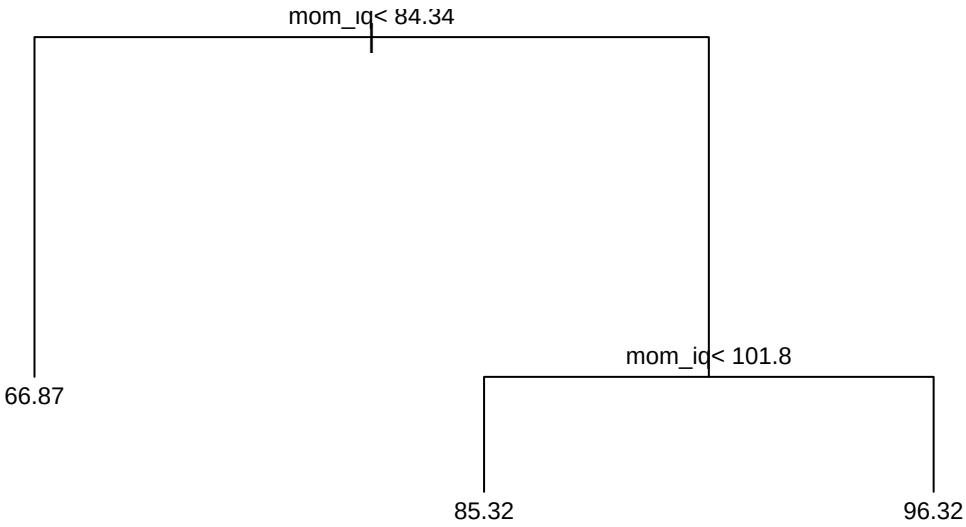

Ojo, estamos seleccionando el arbol con mayor R2 de acuerdo a validación cruzada (variable xerror). Si nos fijamos en el árbol con menor error de acuerdo a la variable *rel error* tendríamos que elegir el árbol de 45 hojas!

5 Prediccion

```
xp = data.frame(mom_iq = 95, mom_age = 30, mom_hs = "si",
                mom_work = "notrabaja")
predict(t4_prune, newdata = xp)
```

```
##        1
## 85.31937
```

- Mirando el arbol se puede verificar fácilmente la predicción.